


Deep Learning




Maria Victoria Santiago Alcalá - Dayana Aguirre Iñiguez

Sistemas Inteligentes para la Gestión en la Empresa

Granada, Junio 2018

Feature map

El mapa de características es la salida de un filtro aplicado a la capa anterior.




Se dibuja un filtro dado en toda la capa anterior, se mueve un píxel a la vez. Cada posición da como resultado una activación de la neurona y la salida se recoge en el mapa de características.

Tamaño del Feature Map

Profundidad: la profundidad corresponde a la cantidad de filtros que usamos para la operación de convolución.


Stride: es el número de píxeles con los que deslizamos nuestra matriz de filtro sobre la matriz de entrada. Mientras mayor sea el número se producirá mapas de características más pequeñas.

Zero-padding: a veces, es conveniente rellenar la matriz de entrada con ceros alrededor del borde, de modo que podamos aplicar el filtro a los elementos que bordean nuestra matriz de imagen de entrada.



Feature Maps también se llaman activaciones intermedias.

- Las primeras capas suelen actuar como detectores de bordes.
- Los mapas de características más profundos codifican conceptos de alto nivel como "nariz de gato" u "oreja de perro", mientras que los mapas de características de nivel inferior detectan bordes y formas simples.




Ensembling ConvNets

Ensemble es un procedimiento potente que mejora el rendimiento de una sola red.

Reduce la porción de varianza en la descomposición de polarización-varianza del error de predicción.

Mejorando así el accuracy de precisión junto con una reducción en el tiempo de entrenamiento.



Técnicas para realizar árboles de decisión ensambles

- **Bagging:** Crear varios subconjuntos de datos de la muestra de entrenamiento elegida al azar con reemplazo. Ahora, cada colección de datos de subconjuntos se usa para entrenar sus árboles de decisión. Como resultado, terminamos con un conjunto de diferentes modelos. Se usa el promedio de todas las predicciones de diferentes árboles.

Random Forest

Desventajas

Como la predicción final se basa en las predicciones medias de los árboles subconjuntos, no proporciona valores precisos para el modelo.

Ventajas

- Maneja muy bien los datos de mayor dimensionalidad.
- Maneja los valores perdidos y mantiene la precisión de los datos faltantes.

Técnicas para realizar árboles de decisión ensambles

- **Boosting:** Ajustar árboles consecutivos (muestra aleatoria) y en cada paso, el objetivo es resolver el error neto del árbol anterior. Cuando una entrada se clasifica erróneamente mediante una hipótesis, su peso aumenta, por lo que es probable que la próxima hipótesis la clasifique correctamente.

Gradient Boosting

Desventajas

- Propenso al exceso de ajuste.
- Requiere ajuste cuidadoso de diferentes hiperparámetros


Ventajas

- Admite diferentes funciones de pérdida.
- Funciona bien con interacciones.

Hybrid CNN

Las redes HCNN combinan la idea original de las redes convolucionales de LeCun con los beneficios de las redes neuronas.


Propuesto



CNN - usa como un extractor de funciones

SVR - como un clasificador

En este modelo, durante la construcción, la capa superior de la CNN tradicional se reemplaza con un clasificador SVR.



- Conjunto de datos se usa como entrada.
- Al comienzo de la etapa de capacitación, los datos brutos del conjunto de datos original se transforman en una matriz con varias dimensiones, y la cual sería nuestra primera capa visible
- La capa de agrupación junto a la capa convolucional usa la regla de agrupación máxima
- La salida de la última capa de agrupación se ingresa a una capa de conexión completa con una salida de 100 dimensiones.
- El feature map se ingresará al clasificador SVR.